
Анализ текстовой коллекции WikIR

Имя Фамилия¹

1. Базовые характеристики коллекции (20)

1. число документов
2. размер коллекции в словах
3. средняя длина документа в словах
4. число уникальных слов
5. средняя длина слова
6. средняя длина уникального слова

Характеристики привел в табл. 1.

2. Стоп-слова (20)

Используем список английских стоп-слов из gist пользователя Sebleier (список стоп-слов NLTK, 179 слов).

Топ-30 наиболее частотных слов и их наличие в стоп-листе приведены в табл. 2.

Топ слов не из стоп-листа, вошедших в ТОП-520, приведён в табл. 3.

Слова из топ-30, не входящие в стоп-лист: first, also. Стоп-слов в тексте: 29 387 785. Их доля в коллекции: 40.2%. Много это или мало? Согласно авторитетному источнику, стоп-слова составляют 40–60% любого корпуса на естественном языке (Manning et al., 2008; Zipf, 1949; ?). Этот корпус вписывается в правило.

Однако этот список стоп-слов составлен очень осторожно. Некоторые слова в not_in_sw называют доммено-нейтральными, потому что они не несут различительной способности для поиска и неоправданно раздувают списки вхождений (postings lists). Кандидаты на расширение стоп-листа: also, one.

Так, слово one's не всегда считается числительным, а часто используется в значении обезличенного местоимения.

Цитируя Cambridge Dictionary,

As a personal pronoun (both subject and object), one can be used to refer to 'people in general'.

We often use one in making generalisations, especially in more formal styles. However, if one is used too much, it can make the speaker sound too formal. One takes a third person singular verb:

Пример:

One should not use mobile phones when driving.

2.1. Закон Ципфа

Закон Ципфа предсказывает, что частота слова в коллекции $\propto 1/\text{ранг}$, что в логарифмических координатах (log-log) даёт прямую с наклоном ≈ -1 . На графике ниже - распределение частотности слов в нашей коллекции.




Figure 1. Закон Ципфа: зависимость ранга от частоты в логарифмических координатах.

2.2. Закон Хипса

Словарь растёт сублинейно с ростом размера корпуса: $V(n) = K \cdot n^\beta$, где обычно $\beta \in [0.4, 0.6]$. На графике ниже - подтверждение закона на базе нашей коллекции.

3. Анализ биграмм и их частот(15)

Топ-31 наиболее частотных биграмм приведён в табл. 4.

Как видим, первая биграмма, являющаяся отдельной лексической единицей, находится на 31 позиции




Figure 2. Закон Хипса: рост словаря в логарифмических координатах.

списка самых популярных биграмм. Посмотрим, как выглядят самые популярные лексически осмысленные биграммы, по 515 позицию (см. табл. 5).

Критерии сохранения биграммы как отдельной записи в инвертированном индексе:

1. Отсутствие стоп-слов — оба компонента должны быть содержательными словами; биграммы, начинающиеся со стоп-слов (of the, in a), добавляют шум и резко увеличивают размер индекса.
2. Алфавитность — оба слова должны проходить проверку `str.isalpha()` (это убирает артефакты пунктуации и числовые токены).
3. Минимальная частота — частота ≥ 5 позволяет не индексировать биграммы-гапаксы (то есть слова, которые встречаются очень-очень редко в корпусе), впуская занимающие место.
4. Семантическая связность — пара должна именовать сущность, понятие или устойчивое выражение (new york, world war, solar system); высокий PMI количественно отражает это.

Колонка «Осмысленно ли?» в табл. 4 применяет критерии 1 и 2 как быстрый первичный фильтр.

4. Морфологическая обработка (25)

Porter stemming. Porter stemming полностью основан на детерминированных правилах и не имеет настраиваемых гиперпараметров. NLTK предоставляет каноническую реализацию алгоритма 1980 года. Мы предпочитаем его Snowball или Lancaster, так как это стандартный базовый метод в IR: умеренно агрессивный, дающий читаемые основы с минимальным избыточным стеммингом. Ожидаемый резуль-

тат: уменьшение размера словаря за счёт объединения суффиксов (running $\rightarrow$ run, studies $\rightarrow$ studi).

Лемматизация spaCy. Модель `en_core_web_sm` — наименее сильная модель в spaCy. spaCy использует хеш-таблицу поиска вместе с морфологическими правилами ;

Модель `bert-base-uncased` — subword-токенизатор WordPiece.

Сравнение результатов обработки коллекции приведено в табл. 6.

Что мы видим?

Стемминг и лемматизация сокращают число уникальных токенов в тексте. Стоит заметить, что словарный запас (столбец Unique tokens) после применения стемминга меньше словарного запаса после лемматизации. Это иллюстрирует эмпирический факт, что стемминг может "склеивать" неоднокоренные слова в одну основу (пример: Caring $\Rightarrow$ car, в то время как лемматизация отобразит Caring $\Rightarrow$ Care). Окончание у слов отбрасываются настолько радикально, насколько это возможно, из-за этого некоторые корни (например, заканчивающиеся на гласную букву), можно и не получить.

Однако самое заметное сокращение размера словаря несет собой BERT tokenizer — уменьшает vocabulary на один порядок. Это происходит потому, что BERT Tokenizer использует алгоритм WordPiece, который строит декартово дерево для хранения токенов (<https://aclanthology.org/2021.emnlp-main.160.pdf>). также BERT Tokenizer увеличивает общее число токенов.

Общее число токенов превышает исходное число слов (редкие словоформы дробятся на части с префиксом ##), но размер словаря уменьшается.

Список литературы

Manning, C. D., Raghavan, P., and Schütze, H. Introduction to Information Retrieval. Cambridge University Press, Cambridge, UK, 2008. URL <https://nlp.stanford.edu/IR-book/>.

Zipf, G. K. Human Behavior and the Principle of Least Effort. Addison-Wesley Press, Cambridge, MA, 1949.

А. Таблицы

Table 1. Базовые статистики коллекции.

Метрика	Значение
Число документов	369 721
Размер коллекции (слов)	73 093 729
Средняя длина документа (слов)	197.7
Число уникальных слов (типов)	794 568
Средняя длина слова	4.795
Средняя длина уникального слова (типа)	7.714

Table 2. Топ-30 наиболее частотных слов и их наличие в стоп-листе.

Ранг	Слово	Частота	В стоп-листе
1	the	5 311 943	да
2	of	2 532 382	да
3	in	2 355 417	да
4	and	2 231 007	да
5	a	1 557 760	да
6	to	1 407 261	да
7	was	1 078 183	да
8	he	685 303	да
9	is	676 829	да
10	as	661 622	да
11	for	616 110	да
12	on	610 583	да
13	with	535 843	да
14	by	526 627	да
15	s	497 472	да
16	at	482 839	да
17	his	440 633	да
18	from	432 326	да
19	it	398 308	да
20	that	306 808	да
21	an	279 228	да
22	which	221 057	да
23	first	217 204	нет
24	are	206 921	да
25	were	205 684	да
26	has	195 167	да
27	also	186 055	нет
28	she	184 297	да
29	after	166 616	да
30	its	161 439	да

Table 3. Топ слов, не входящих в стоп-лист.

Ранг	Слово	Частота
23	first	217 204
27	also	186 055
32	one	157 573
37	new	139 850
38	two	136 427
42	school	119 897
44	university	107 386
50	time	95 373
54	1	89 967
55	years	88 565
56	year	85 032
59	later	80 738
60	became	80 151
61	city	77 682
63	world	77 013
64	three	76 155
66	known	73 969
69	state	70 280
71	national	69 849
72	part	69 635
73	united	68 263
74	2	67 911
76	born	66 729
79	made	65 449
80	team	64 448
81	may	62 403
83	season	61 403
84	second	61 249
85	south	60 500
86	high	60 138

Table 4. Топ-31 наиболее частотных биграмм.

Биграмма	Частота	Осмыленно ли?
of the	768 320	нет
in the	546 863	нет
to the	256 451	нет
at the	201 351	нет
and the	170 394	нет
on the	169 708	нет
he was	163 554	нет
as a	163 073	нет
for the	159 502	нет
by the	130 810	нет
with the	120 118	нет
from the	115 219	нет
the first	104 264	нет
it was	101 387	нет
as the	96 915	нет
it is	95 880	нет
is a	82 161	нет
was a	78 342	нет
in a	76 786	нет
one of	70 278	нет
was the	69 881	нет
of a	69 345	нет
with a	63 880	нет
is the	63 672	нет
to be	62 139	нет
and was	58 478	нет
during the	56 159	нет
and a	56 121	нет
part of	54 180	нет
the united	49 922	нет
united states	48 952	да

Table 5. Самые популярные лексически осмысленные биграммы (позиции 31–515).

Порядковый №	Биграмма	Частота
31	united states	48 952
41	new york	38 477
59	high school	29 895
91	world war	20 915
253	war ii	10 432
255	york city	10 401
266	los angeles	10 042
325	two years	9 013
343	new zealand	8 764
436	years later	7 412
438	best known	7 391
455	also known	7 198
488	united kingdom	6 924
515	first time	6 640

Table 6. Базовые статистики для стеммированной, лемматизированной и BERT-токенизированной версий коллекции.

Метод обработки	Всего токенов	Средняя длина документа	Уникальных токенов	Средняя длина токена	Средняя длина уникального
Без доп. токенизации	73 093 729	197.70	794 568	4.80	7.71
Porter Stemming	73 093 729	197.70	684 579	4.26	7.34
spaCy lemmatization	73 106 364	197.73	759 322	4.59	7.64
BERT tokenization	81 185 427	219.59	27 528	4.52	6.63